

## 第 6 讲：分类费率厘定 2 - 广义线性模型

高光远

中国人民大学 统计学院

# 主要内容

- ① 广义线性模型
  - 指数型分布族
  - 连接函数
  - 常见的指数型分布
- ② 参数估计
  - 迭代加权最小二乘法
  - 离散参数的估计
  - 极大似然估计的大样本性质
- ③ 预测和检验
  - 预测
  - 检验

## 分类费率厘定模型：确定性 VS 随机性

- 从精算角度考虑，费率因子需要和潜在损失相关.
- 潜在损失观测不到，只能看到经验损失 (随机变量).
- 利用经验损失数据，检验费率因子的统计显著性.
- 确定性模型无法进行统计检验，需要建立随机性模型.

# 线性回归模型 (linear regression, linear model)

$$Y_i \stackrel{ind}{\sim} N(\mu_i, \sigma^2) \text{ with } \mu_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_d x_{id}, \quad i = 1, \dots, n.$$

基本假设:

- ①  $Y_i$  互相独立.
- ② 方差不随期望的改变而变化.
- ③  $Y_i$  服从正态分布.
- ④  $Y_i$  的期望  $\mu_i$  和协变量  $\mathbf{x}_i$  线性相关.

# 广义线性模型 (generalized linear model, GLM)

$Y_i \stackrel{ind}{\sim} \text{EDF}(\mu_i, \phi)$  with  $g(\mu_i) = \eta_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_d x_{id}$ ,  $i = 1, \dots, n$ .

基本假设:

- ①  $Y_i$  互相独立.
- ② 方差可以随期望的改变而变化.
- ③  $Y_i$  服从指数型分布族 (exponential dispersion family, EDF). 其离散系数 (dispersion) 为  $\phi$ .
- ④  $Y_i$  的期望  $\mu_i$  通过连接函数 (link function)  $g$  和协变量  $\mathbf{x}_i$  线性相关.

# 自然参数和离散参数

指数分布族的概率密度函数可以表示为

$$f(y_i; \theta_i, \phi) = \exp \left[ \frac{y_i \theta_i - b(\theta_i)}{a(\phi)} + c(y_i, \phi) \right]$$

- $\theta_i$  称为**自然参数 (natural parameter)**, 不等于均值但和均值有关.
- $\phi$  称为**离散参数 (dispersion parameter)**, 不等于方差但和方差有关.
- 每个观察值有**不同的**自然参数, 但有**相同的**离散参数.

## 期望和方差

- 函数  $a(\phi)$  通常为  $\phi/\omega_i$ , 其中  $\omega_i$  表示  $y_i$  的权重, 反映了  $y_i$  的相对可信度.
- 通常, 当  $Y_i$  表示第  $i$  个风险集合的平均索赔次数时, 权重为该风险集合的风险单位数; 当  $Y_i$  表示第  $i$  个风险集合的平均索赔金额时, 权重为该风险集合的赔付次数.
- $Y_i$  的期望为  $\mathbb{E}(Y_i) = \mu_i = b'(\theta_i)$ . 期望由自然参数唯一确定, 和  $\phi$  无关.
- 函数  $c(y_i, \phi)$  和自然参数无关, 进而和期望无关. 因此也不会影响回归参数  $\beta$  的估计.
- $Y_i$  的方差为

$$\text{Var}(Y_i) = a(\phi)b''(\theta_i) = \phi b''(\theta_i)/\omega_i$$

- 定义方差函数 (variance function)

$$V(\mu_i) = b''(\theta_i)/\omega_i$$

注: 连接函数的选择不影响分布.

- 期望  $\mu_i$  通过连接函数  $g$ , 与线性预测项 (linear predictor)  $\eta_i$  关联:

$$g(\mu_i) = \eta_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_d x_{id} = \langle \beta, \mathbf{x}_i \rangle.$$

- 规范连接函数 (canonical link function)

$$g_c(\mu_i) = \theta_i.$$

即  $g_c$  为  $b'$  的逆函数. 当选用规范连接函数时, 自然参数等于线性预测项.

- 常见的规范连接函数有: 恒等 (正态), 对数 (泊松), 倒数 (伽马). 在 logistic 回归中, 常使用 Logit 连接函数, 即

$$g(\mathbb{E}(Y_i)) = g(p_i) = \ln \frac{p_i}{1 - p_i} = \langle \beta, \mathbf{x}_i \rangle$$



	Normal	Poisson	Binomial	Gamma	Inverse Gaussian
$f(y)$	$\frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(y-\mu)^2}{2\sigma^2}\right)$	$\frac{\mu^y \exp(-\mu)}{y!}$	$\binom{n}{y} \left(\frac{\mu}{n}\right)^y \left(1 - \frac{\mu}{n}\right)^{n-y}$	$\frac{1}{\Gamma(\nu)} \left(\frac{\nu}{\mu}\right)^\nu y^{\nu-1} \exp\left(-\frac{\nu y}{\mu}\right)$	$\sqrt{\frac{\gamma}{2\pi y^3}} \exp\left[\frac{-\gamma(y-\mu)^2}{2\mu^2 y}\right]$
Range	$-\infty < y < \infty$	$y = 0, 1, 2, \dots$	$y = 0, 1, \dots, n$	$y > 0$	$y > 0$
$\theta$	$\mu$	$\log(\mu)$	$\log\left(\frac{\mu}{n-\mu}\right)$	$-\frac{1}{\mu}$	$\frac{-1}{2\mu^2}$
$\phi$	$\sigma^2$	1	1	$\frac{1}{\nu}$	$\frac{1}{\gamma}$
$a(\phi)$	$\phi (= \sigma^2)$	$\phi (= 1)$	$\phi (= 1)$	$\phi (= \frac{1}{\nu})$	$\phi (= \frac{1}{\gamma})$
$b(\theta)$	$\frac{\theta^2}{2}$	$\exp(\theta)$	$n \log(1 + e^\theta)$	$-\log(-\theta)$	$-\sqrt{-2\theta}$
$c(y, \phi)$	$-\frac{1}{2} \left[ \frac{y^2}{\phi} + \log(2\pi\phi) \right]$	$-\log(y!)$	$\log \binom{n}{y}$	$\nu \log(\nu y) - \log(y\Gamma(\nu))$	$-\frac{1}{2} \left[ \log(2\pi y^3 \phi) + \frac{1}{\phi y} \right]$
$V(\mu)$	1	$\mu$	$\mu(1 - \mu/n)$	$\mu^2$	$\mu^3$
$g_c(\mu)$	$\mu$	$\log(\mu)$	$\frac{\mu}{n-\mu}$	$\frac{1}{\mu}$	$\frac{1}{\mu^2}$
$D(y, \hat{\mu})$	$(y - \hat{\mu})^2$	$2y \log\left(\frac{y}{\hat{\mu}}\right) - 2(y - \hat{\mu})$	$2 \left[ y \log\left(\frac{y}{\hat{\mu}}\right) + (n - y) \log\left(\frac{n-y}{n-\hat{\mu}}\right) \right]$	$2 \left[ \frac{y-\hat{\mu}}{\hat{\mu}} - \log\left(\frac{y}{\hat{\mu}}\right) \right]$	$\frac{(y-\hat{\mu})^2}{\hat{\mu}^2 y}$

Table 2.1 Some Exponential Family Distributions. Note that when  $y = 0$ ,  $y \log(y/\hat{\mu})$  is replaced by zero (its limit as  $y \rightarrow 0$ ).

# Version 1

- $g(\mu_i)$  和协变量**线性相关**. 可以对  $g(\mu_i)$  和协变量进行回归分析. 但是,  $\mu_i$  不知道, 暂用  $y_i$  代替.
- 利用 Taylor 展开式, 可知  $g(Y_i)$  的方差近似为

$$\text{Var}(g(Y_i)) \approx \text{Var}(Y_i)g'(\mu_i)^2 = \phi V(\mu_i)g'(\mu_i)^2. \quad (1)$$

上述方法也称为**delta method**.

- 数据的离散度越大, 其可信度越低. 在  $g(Y_i)$  和协变量的回归分析中, 需要使用**加权最小二乘法 (weighted least squares)**, 相对权重为**方差的倒数**:

$$w_i = \frac{1}{V(\mu_i)g'(\mu_i)^2}.$$

- $\phi$  为常数, 在相对权重中可以省略, 不影响参数估计.

## Version 1

迭代加权最小二乘法 1 (iterative re-weighted least squares, IRLS):

给定初始  $\hat{\mu}_i^0 = y_i$ , 计算  $w_i^0 = 1/(V(\hat{\mu}_i^0)g'(\hat{\mu}_i^0)^2)$ . 第  $t$  步迭代为:

- ① 以  $w_i^{t-1}$  为权重, 通过如下加权最小二乘法求得  $\hat{\beta}^t$ :

$$\arg \min_{\beta} \sum_{i=1}^n w_i^{t-1} (g(\hat{\mu}_i^{t-1}) - \langle \beta, \mathbf{x}_i \rangle)^2$$

$\hat{\beta}^t$  的解析解为  $\hat{\beta}^t = (X^T W X)^{-1} X^T W Y$ , 其中  $X$  为设计矩阵 (design matrix),  $W = \text{diag}(w_1^{t-1}, \dots, w_n^{t-1})$ .

- ② 计算新的期望  $\hat{\mu}_i^t = g^{-1}(\langle \hat{\beta}^t, \mathbf{x}_i \rangle)$  和新的权重:

$$w_i^t = \frac{1}{V(\hat{\mu}_i^t)g'(\hat{\mu}_i^t)^2}.$$

重复以上两步, 最终可以求出  $\beta$  的极大似然估计.

## Version 2

假设有  $n$  个观测值, 全样本可表示为  $\mathcal{D} = (\mathbf{x}_i, y_i)_{i=1:n}$ . 可以推出其对数似然函数为

$$l(\beta|\mathcal{D}) = \sum_{i=1}^n \frac{y_i \theta_i - b(\theta_i)}{a(\phi)} + c(\phi, y_i) = \sum_{i=1}^n \frac{\omega_i [y_i \theta_i - b(\theta_i)]}{\phi} + c(\phi, y_i)$$

上式关于  $\beta_j$  求偏导

$$\frac{\partial l}{\partial \beta_j} = \frac{1}{\phi} \sum_{i=1}^n \omega_i \left( y_i \frac{\partial \theta_i}{\partial \beta_j} - b'(\theta_i) \frac{\partial \theta_i}{\partial \beta_j} \right) = \frac{1}{\phi} \sum_{i=1}^n \omega_i [y_i - b'(\theta_i)] \frac{\partial \theta_i}{\partial \beta_j} \quad (2)$$

其中,

$$\frac{\partial \theta_i}{\partial \beta_j} = \frac{\partial \theta_i}{\partial \mu_i} \frac{\partial \mu_i}{\partial \beta_j} = \frac{1}{b''(\theta_i)} \frac{\partial \mu_i}{\partial \beta_j}.$$

## Version 2

式 (2) 进一步等于

$$\frac{\partial l}{\partial \beta_j} = \frac{1}{\phi} \sum_{i=1}^n \frac{y_i - b'(\theta_i)}{b''(\theta_i)/\omega_i} \frac{\partial \mu_i}{\partial \beta_j} = \frac{1}{\phi} \sum_{i=1}^n \frac{y_i - \mu_i}{V(\mu_i)} \frac{\partial \mu_i}{\partial \beta_j} \quad (3)$$

所以,  $\beta$  的极大似然估计, 为以下方程组的解

$$\sum_{i=1}^n \frac{y_i - \mu_i}{V(\mu_i)} \frac{\partial \mu_i}{\partial \beta_j} = 0 \quad \forall j \quad (4)$$

如果式 (4) 中  $V(\mu_i)$  为已知, 且和  $\beta$  独立, 则式(4)对应于一个**非线性加权最小二乘法**, 其目标函数为:

$$\mathcal{S} = \sum_{i=1}^n \frac{(y_i - \mu_i)^2}{V(\mu_i)} \quad (5)$$

## Version 2

迭代加权最小二乘法 2 (iterative re-weighted least squares, IRLS)

给定初始  $\hat{\beta}^0$ , 计算  $V(\hat{\mu}_i^0) = V(g^{-1}(\langle \hat{\beta}^0, \mathbf{x}_i \rangle))$ . 第  $t$  步迭代为:

- ① 以  $1/V(\hat{\mu}_i^{t-1})$  为权重, 通过非线性加权最小二乘法 (5) 求得  $\hat{\beta}^t$ .
- ② 计算  $V(\hat{\mu}_i^t) = V(g^{-1}(\langle \hat{\beta}^t, \mathbf{x}_i \rangle))$ .

重复以上两步, 最终可以求出  $\beta$  的极大似然估计.

# Pearson 方法

定义Pearson 统计量为

$$X^2 = \sum_{i=1}^n \frac{(y_i - \hat{\mu}_i)^2}{V(\hat{\mu}_i)}$$

当样本足够大, 近似地,

$$\frac{X^2}{\phi} \sim \chi_{n-d-1}^2.$$

所以, 离散参数  $\phi$  的估计为

$$\hat{\phi}_P = \frac{X^2}{n-d-1}.$$

此方法为 R 估计离散参数的方法.

## 偏差 (deviance)

- 定义偏差统计量 (deviance, deviance statistics) 为

$$D(\hat{\beta}_{full}, \hat{\beta}) = 2\phi[l(\hat{\beta}_{full}) - l(\hat{\beta})].$$

其中  $\hat{\beta}_{full}$  为饱和模型 (saturated model) 的参数估计.

- 在饱和模型中, 一个因变量对应一个期望参数  $\mu_i$ , 共有  $n$  个 (回归) 参数. 可以推出, 参数的极大似然估计为  $\hat{\mu}_i = y_i$ .
- 因此, 计算  $\phi l(\hat{\beta}_{full})$  时, 只需要知道因变量的值, 不需要知道协变量的值,  $l(\hat{\beta}_{full})$  也常记作  $l(\mathbf{y})$ .
- 符号  $\hat{\beta}_{full}$  主要为了和  $\hat{\beta}$  对比, 并没有实际意义.
- 偏差统计量类似于 sum of squared error (SSE), 反映了拟合优度. 可以证明, 在高斯分布条件下, Deviance=SSE.
- Deviance 和 SSE 的缺点是对过拟合不敏感.



# 偏差法

- 定义scaled-偏差统计量 (scaled deviance)为

$$D^*(\hat{\beta}_{full}, \hat{\beta}) = D(\hat{\beta}_{full}, \hat{\beta})/\phi = 2[l(\hat{\beta}_{full}) - l(\hat{\beta})].$$

- 关于常见指数型分布的偏差统计量, 请参考第 9页
- 可以证明  $D(\hat{\beta}_{full}, \hat{\beta})$  和  $\phi$  无关,  $D^*(\hat{\beta}_{full}, \hat{\beta})$  和  $\phi$  有关. (作业)
- 若模型正确且样本足够大,  $D^*(\hat{\beta}_{full}, \hat{\beta}) = D(\hat{\beta}_{full}, \hat{\beta})/\phi$  近似服从  $\chi_{n-d-1}^2$ . 所以, 离散参数的另外一种估计方法为:

$$\hat{\phi}_D = \frac{D(\hat{\beta}_{full}, \hat{\beta})}{n - d - 1}.$$

- 在线性回归中, 上式可写为:

$$\hat{\sigma}^2 = \text{MSE} = \frac{\text{SSE}}{n - d - 1}$$

定义费雪信息 (Fisher information matrix) 如下

$$\mathcal{I}(\beta) = \left( -\mathbb{E} \left[ \frac{\partial^2 l(\beta)}{\partial \beta_l \partial \beta_r} \right] \right)_{0 \leq l, r \leq d+1} \quad (6)$$

当样本足够大时, 可以证明

$$\hat{\beta} \sim N(\beta, \mathcal{I}(\beta)^{-1}) \quad (7)$$

可以看到极大似然估计为无偏估计.

根据(7)可以做假设检验 (Hypothesis testing), 如

$$H_0 : \beta_r = 0.$$

在索赔频率回归模型中, 上面的假设检验即检验第  $r$  个分类变量和索赔频率的相关性是否统计显著.

# 预测

- $Y_i$  的期望为  $\mu_i$ .  $\mu_i$  为常数, 可通过  $\hat{\beta}, \mathbf{x}_i$  进行估计

$$\hat{\mu}_i = g^{-1}(\langle \hat{\beta}, \mathbf{x}_i \rangle).$$

- 通过 Taylor 展开,  $\hat{\mu}_i$  的估计方差为:

$$\text{Var}(\hat{\mu}_i) \approx \frac{\mathbf{x}_i^T \text{Var}(\hat{\beta}) \mathbf{x}_i}{g'(\hat{\mu}_i)^2}. \quad (8)$$

- 随机变量  $Y_i$  也可以通过  $\hat{Y}_i = \hat{\mu}_i$  进行预测. 其预测均方误差 (mean square error of prediction, MSE<sub>P</sub>) 为

$$\mathbb{E} \left[ (Y - \hat{Y})^2 \right] = \left( \mathbb{E}[Y] - \mathbb{E}[\hat{Y}] \right)^2 + \text{Var}(\hat{Y}) + \text{Var}(Y). \quad (9)$$

其中, 右边第一项称为偏差 (bias), 第二项称为估计方差 (estimation variance), 最后一项称为过程方差 (process variance).

# Pearson residuals

定义Pearson 残差为

$$\epsilon_i^P = \frac{y_i - \hat{\mu}_i}{\sqrt{V(\hat{\mu}_i)}}.$$

定义 scaled-Pearson 残差为

$$\epsilon_i^{SP} = \frac{y_i - \hat{\mu}_i}{\sqrt{\phi V(\hat{\mu}_i)}}.$$

可知

$$X^2 = \sum_{i=1}^n (\epsilon_i^P)^2$$

# Deviance residuals

定义偏差残差 (deviance residuals) 为

$$\epsilon_i^D = \text{sign}(y_i - \hat{\mu}_i) \sqrt{2\phi[l_i(\hat{\beta}_{full}) - l_i(\hat{\beta})]}.$$

其中,  $l_i$  表示第  $i$  个样本的对数似然函数.

定义 scaled-偏差残差 (scaled-deviance residuals) 为

$$\epsilon_i^{SD} = \text{sign}(y_i - \hat{\mu}_i) \sqrt{2[l_i(\hat{\beta}_{full}) - l_i(\hat{\beta})]}.$$

可知

$$D(\hat{\beta}_{full}, \hat{\beta}) = \sum_{i=1}^n (\epsilon_i^D)^2$$

在理想的残差图中, 残差应该在原点两侧对称随机分布, 并没有明显的模式. 否则, 需要重新考虑分布的选取, 或者连接函数的选取.

# 正态检验

根据参数极大似然估计的大样本性质:

$$\hat{\beta} \sim N(\beta, \mathcal{I}(\beta)^{-1})$$

可以给出每个参数的置信区间, 进而进行假设检验. 如  $H_0: \beta_r = 0$  或  $H_0: \beta_r = 2$ .

# 似然比检验

检验模型中某些协变量和因变量的相关性是否统计显著.

$$H_0 : \beta_1 = \dots = \beta_p = 0 \text{ for } 1 \leq p < d$$

- ① 计算完整模型的 scaled-偏差统计量  $D^*(\hat{\beta}_{full}, \hat{\beta})$
- ② 计算在  $H_0$  下模型的 scaled-偏差统计量  $D^*(\hat{\beta}_{full}, \hat{\beta}_{H_0})$
- ③ 定义检验统计量

$$D^*(\hat{\beta}, \hat{\beta}_{H_0}) = D^*(\hat{\beta}_{full}, \hat{\beta}_{H_0}) - D^*(\hat{\beta}_{full}, \hat{\beta}) = 2[l(\hat{\beta}) - l(\hat{\beta}_{H_0})] \quad (10)$$

- ④ 在  $H_0$  下,  $D^*(\hat{\beta}, \hat{\beta}_{H_0}) \sim \chi_{p_1 - p_0}^2$ . 在  $\alpha$  的显著水平下, 如果

$$D_{H_0} \geq \chi_{p_1 - p_0}^2(1 - \alpha),$$

拒绝  $H_0$ . 这里  $p_1 = d + 1$  为完整模型  $\beta$  参数的个数,  
 $p_0 = d + 1 - p$  为  $H_0$  模型  $\beta$  参数的个数.  $p_1 - p_0 = p$ .



# 正态检验 VS 似然比检验

- 正态检验类似于线性回归中的  $t$  检验, 每次只能检验一个协变量的显著性.
- 似然比检验类似于线性回归中的  $F$  检验, 可以同时检验多个协变量的显著性, 也可以检验  $H_0 : \beta_s = \beta_t$ .

- ① 阅读教材 117-125 页.
- ② 完成 128 页习题 4.7.
- ③ 证明式 (1), 式 (8), 式 (9).
- ④ 证明  $D(\hat{\beta}_{full}, \hat{\beta})$  和  $\phi$  无关,  $D^*(\hat{\beta}_{full}, \hat{\beta})$  和  $\phi$  有关.
- ⑤ 证明  $D(\hat{\beta}_{full}, \hat{\beta}) \geq 0$ .